

Projet de Prédiction des Loyers à Bujumbura (rent_prediction.csv)

Synthèse : Ce document récapitule les observations factuelles tirées de l'analyse exploratoire des données ainsi que les décisions techniques de prétraitement pour la phase de modélisation.

Variable / Aspect	Données Observées (EDA)	Action / Décision Technique	Justification Technique
Qualité Lignes Manquantes	25 lignes totalement vides sur l'ensemble des descripteurs (485 non-nulls sur 510).	Suppression directe des 25 lignes concernées.	Données manquantes de manière simultanée (MCAR/MAR). La suppression évite d'injecter du bruit lors des imputations.
Anomalie AgeMaison	Valeur maximale aberrante de 2 600 000 ans (fuite possible de la valeur du loyer).	Remplacement des valeurs > 100 par NaN puis imputation par la médiane selon le Quartier.	Corrige une erreur manifeste de saisie tout en préservant la cohérence géographique globale.
Cible LoyerMensuel_BIF	Distribution asymétrique à droite + effet de plafonnement/seuil marqué à 2 600 000 BIF.	Passage de la cible au log (log1p) pour lisser l'asymétrie + test d'un modèle adapté aux données censurées.	Rapproche la cible d'une distribution normale, ce qui stabilise la variance et améliore la convergence des modèles.
Colinéarité Chambres & Superficie_m2	Corrélation quasi-parfaite de 0.98 entre les deux variables + corrélation de 0.62 avec le loyer.	Conservation de Superficie_m2 pour modèles linéaires (ou ratio) ; conservation des deux pour modèles d'arbres.	Évite la multicolinéarité sévère qui déstabilise les coefficients des régressions linéaires.
Catégorielle Quartier	Forte hiérarchie des prix : Rohero/Kiriri très élevés vs Buyenzi/Bwiza très bas.	Application d'un Target Encoding (ou Ordinal Encoding basé sur le loyer médian).	Conserve l'information spatiale et la valeur foncière sans exploser la dimensionnalité du modèle.
Feature Eng. Équipements	Impact positif net des équipements (Meuble, Jardin, Salon, SdB) sur le loyer médian.	Création d'une feature composite Standing_Score (somme des équipements présents).	Synthétise le niveau de confort général du bien en une seule variable explicative synthétique.
Faible Impact DistanceRoute_m	Très faible corrélation linéaire directe avec le loyer (~0.02).	Test d'une binarisation (ex: Proche < 200m vs Éloigné) ou sélection par régularisation (Lasso).	Transforme une variable continue peu explicative en un seuil de proximité plus pertinent.
Faible Impact Parking	Faible différenciation sur la distribution des loyers entre Oui et Non.	Simplification ou faible pondération lors du Feature Engineering.	Évite de surcharger les modèles avec des variables peu discriminantes.